

1. Introducción

Este documento describe el diseño formal y la implementación del analizador léxico de PromptZal, desarrollado para el Proyecto 1 del curso de Lenguajes Formales y de Programación. Se presenta el autómata finito determinista (AFD) que reconoce las categorías léxicas del lenguaje, su gramática regular equivalente, la tabla completa de tokens, y la estrategia de manejo y recuperación de errores léxicos.

El alcance de este proyecto es estrictamente el análisis léxico: el programa reconoce y clasifica tokens, y reporta errores léxicos; no interpreta ni ejecuta el lenguaje PromptZal.

1.1 Decisión de diseño: implementación desde cero

A diferencia de la Práctica 1, este proyecto se implementó con una base de código completamente nueva, en lugar de extender directamente el código de la práctica anterior. Esta decisión fue consultada y autorizada explícitamente por el auxiliar del curso antes de iniciar el desarrollo, dado que el AFD formal requerido por este proyecto es considerablemente más grande y estructurado que el reconocido de manera informal en la práctica.

No obstante, se mantienen conscientemente los mismos principios de diseño que resultaron efectivos en la Práctica 1: arquitectura de responsabilidad única (separación entre modelo, analizador léxico, generación de reportes y GUI), la filosofía de recuperación de errores ("descartar lo mínimo necesario y continuar"), y la línea visual de la interfaz gráfica (barra lateral de navegación con tarjetas de resumen).

2. Autómata Finito Determinista (AFD)

El AFD se define formalmente como la tupla $(Q, \Sigma, \delta, q_0, F)$, donde:


$Q = \{ S_0, S_1, S_2, S_{2b}, S_{2c}, S_3, S_{3b}, S_4, S_5, S_6, S_{6a}, S_{6b}, S_{6c}, q_E \}$

Σ = alfabeto de entrada, agrupado en clases: letra, dígito, y los símbolos individuales @ " { } () = + - > . / * _ y el salto de línea.

$q_0 = S_0$ (estado inicial)

$F = \{ S_1, S_2, S_{2c}, S_{3b}, S_4 \text{ (al cerrar comilla)}, S_5 \text{ (al ver '>')}, S_{6a}, \text{ y cada uno de los símbolos de un carácter: } =, +, \{, \}, (,) \}$

2.1 Diagrama del AFD



Ambas representaciones (la dibujada manualmente y la generada por Graphviz a partir del código DOT) corresponden al mismo autómata descrito en este documento.

2.2 Tabla de transiciones

Estado origen	Entrada	Estado destino	Observación
S0	letra	S1	inicio de identificador/reservada
S1	letra dígito _	S1	ciclo (acepta en cada paso)
S1	otro	S0	acepta: consulta tabla de reservadas
S0	dígito	S2	inicio de entero
S2	dígito	S2	ciclo (acepta ENTERO)
S2	.	S2b	posible decimal
S2	otro	S0	acepta ENTERO
S2b	dígito	S2c	—
S2b	otro	qE	error: decimal mal formado
S2c	dígito	S2c	ciclo (acepta DECIMAL)

S2c	otro	S0	acepta DECIMAL
S0	@	S3	inicio de directiva
S3	letra	S3b	—
S3	otro	qE	error: carácter inválido tras @
S3b	letra	S3b	ciclo
S3b	otro	S0	acepta si @modelo/@rol/@formato; si no, error
S0	comilla	S4	inicio de cadena
S4	cualquiera ≠ " y ≠ \n	S4	ciclo
S4	comilla	S0	acepta CADENA
S4	\n o EOF	qE	error: cadena sin cerrar
S0	-	S5	posible flecha
S5	>	S0	acepta FLECHA (->)

S5	otro	qE	error: '-' no es operador válido solo
S0	/	S6	posible comentario
S6	/	S6a	comentario de línea
S6	*	S6b	comentario de bloque
S6	otro	qE	error: '/' no es operador válido
S6a	cualquiera ≠ \n	S6a	ciclo, sin token
S6a	\n o EOF	S0	cierra comentario de línea, sin token
S6b	cualquiera (incluye \n)	S6b	ciclo, sin token
S6b	*	S6c	posible cierre
S6b	EOF	qE	error: comentario sin cerrar
S6c	/	S0	cierra comentario de bloque, sin token
S6c	*	S6c	ciclo (maneja "***/")

S6c	otro	S6b	no cerró, regresa al cuerpo
S6c	EOF	qE	error: comentario sin cerrar
S0	=, +, {, }, (,)	S0	acepta token de un carácter directo
S0	espacio, tab, \n	S0	se descarta, sin token
S0	otro no reconocido	qE	error: carácter no reconocido

3. Gramática regular

La gramática regular $G = (N, T, P, S)$ se derivó formalmente a partir del AFD, aplicando la regla estándar: para cada transición $\delta(A, a) = B$ se agrega la producción $A \rightarrow aB$; si B es un estado de aceptación, se agrega también $A \rightarrow a$. Todas las producciones tienen la forma $A \rightarrow aB$ o $A \rightarrow a$; no se utiliza ninguna producción $A \rightarrow \lambda$, dado que ningún lexema válido de PromptZal es la cadena vacía.

$N = \{ S0, S1, S2, S2b, S2c, S3, S3b, S4, S5, S6, S6a, S6b, S6c \}$

$T = \{ \text{letra, dígito, @, ", -, >, ., /, *, _}, \text{ y los símbolos individuales } = + \{ \} () \}$

S (símbolo inicial) = $S0$

3.1 Producciones por categoría

Identificadores y palabras reservadas

$S0 \rightarrow \text{letra } S1$

$S0 \rightarrow \text{letra}$

$S1 \rightarrow \text{letra } S1 \mid \text{dígito } S1 \mid _ S1$

$S1 \rightarrow \text{letra} \mid \text{digito} \mid _$

Números (enteros y decimales)

$S0 \rightarrow \text{digito } S2$

$S0 \rightarrow \text{digito}$

$S2 \rightarrow \text{digito } S2$

$S2 \rightarrow \text{digito}$

$S2 \rightarrow . S2b$

$S2b \rightarrow \text{digito } S2c$

$S2b \rightarrow \text{digito}$

$S2c \rightarrow \text{digito } S2c$

$S2c \rightarrow \text{digito}$

Directivas

$S0 \rightarrow @ S3$

$S3 \rightarrow \text{letra } S3b$

$S3 \rightarrow \text{letra}$

$S3b \rightarrow \text{letra } S3b$

$S3b \rightarrow \text{letra}$

Cadenas de texto

$S0 \rightarrow " S4$

$S4 \rightarrow \text{cualquiera } S4 \quad (\text{cualquiera} \neq " \text{ y } \neq \backslash n)$

$S4 \rightarrow "$

Flecha

$S0 \rightarrow - S5$

$S5 \rightarrow >$

Comentario de línea

$S0 \rightarrow / S6$

$S6 \rightarrow / S6a$

$S6 \rightarrow /$

$S6a \rightarrow \text{cualquiera } S6a \quad (\text{cualquiera} \neq \backslash n)$

$S6a \rightarrow \text{cualquiera}$

Comentario de bloque

$S6 \rightarrow * S6b$

$S6b \rightarrow \text{cualquiera } S6b \quad (\text{incluye } \backslash n)$

$S6b \rightarrow * S6c$

$S6c \rightarrow * S6c$

$S6c \rightarrow /$

$S6c \rightarrow \text{cualquiera } S6b$

Símbolos de un carácter (directo desde S0)

$S0 \rightarrow =$

$S0 \rightarrow +$

$S0 \rightarrow \{$

$S0 \rightarrow \}$

$S0 \rightarrow ($

$S0 \rightarrow)$

Nota: la gramática describe el lenguaje de lexemas válidos. Las rutas de error del AFD (caídas a qE) no tienen producción asociada: un error léxico es, por definición, una cadena que no pertenece a L(G).

4. Tabla de tokens

Categoría	Elemento(s)	TipoToken
Directivas	@modelo, @rol, @formato	DIRECTIVA_MODELO, DIRECTIVA_ROL, DIRECTIVA_FORMATO
Estructura	AGENTE, contexto, variable, EJECUTAR, EXPORTAR	AGENTE, CONTEXTO, VARIABLE, EJECUTAR, EXPORTAR
Comandos de IA	PREGUNTAR, GENERAR, RESUMIR, ANALIZAR, TRADUCIR, CLASIFICAR, EXTRAER	(mismo nombre en TipoToken)
Función del sistema	CARGAR	CARGAR

Conectores	SOBRE, DESDE, EN, COMO, ->	SOBRE, DESDE, EN, COMO, FLECHA
Identificador	nombres definidos por el usuario	IDENTIFICADOR
Literales	enteros, decimales, cadenas "..."	ENTERO, DECIMAL, CADENA
Operadores	=, +	ASIGNACION, CONCATENACION
Delimitadores	{ } ()	LLAVE_ABRE, LLAVE_CIERRA, PAR_ABRE, PAR_CIERRA

5. Manejo y recuperación de errores léxicos

La filosofía de recuperación aplicada es: ante un carácter o secuencia inválida, el analizador descarta lo mínimo necesario para quedar en un estado válido, y continúa el análisis desde ahí. Esto permite que un archivo con múltiples errores los reporte todos en una sola corrida, en lugar de detenerse en el primero.

Tipo de error	Se detecta cuando...	Recuperación aplicada
CARACTER_NO_RECONOCIDO	S0 recibe un carácter fuera de todas las clases conocidas	Se descarta ese único carácter y se continúa en S0
CADENA_SIN_CERRAR	Dentro de S4 se encuentra '\n' o EOF antes de la comilla de cierre	No se consume el '\n'; se reporta el error con la posición de apertura y se continúa en S0 en la siguiente línea

DECIMAL_MAL_FORMADO	Tras el punto decimal (S2b) no sigue un dígito	Se reporta el error con lo acumulado hasta el punto; se continúa en S0
DIRECTIVA_INVALIDA	Tras '@' (S3) no sigue una letra	Se reporta el error; se continúa en S0
DIRECTIVA_DESCONOCIDA	El lexema completo tras '@' no coincide con @modelo/@rol/@formato	Se reporta el error con el lexema completo; se continúa en S0
OPERADOR_INVALIDO	'-' no seguido de '>' (S5), o '/' no seguido de '/' ni '*' (S6)	Se descarta el símbolo inicial; se continúa en S0
COMENTARIO_SIN_CERRAR	Un comentario de bloque (S6b/S6c) llega a EOF sin encontrar '*'	Se reporta el error; el análisis termina de forma controlada al llegar a EOF

Caso especial — cadenas y el carácter de salto de línea: dentro de S4 no existe ninguna transición definida hacia un estado de aceptación cuando el símbolo de entrada es '\n'. Por diseño, las cadenas de PromptZal viven en una sola línea; por eso, cualquier '\n' encontrado en S4 provoca la caída a qE. Este mismo hecho se refleja en la gramática regular: no existe ninguna producción que utilice '\n' dentro de las producciones de S4, ya que el lenguaje de cadenas válidas nunca las contiene.

6. Conclusiones

El analizador léxico de PromptZal fue implementado de forma manual, sin el uso de generadores de analizadores léxicos ni de expresiones regulares de Java, guiado explícitamente por el AFD documentado en este manual. Cada método del Lexer corresponde a un estado del autómata, lo que permite trazar y explicar el comportamiento del programa estado por estado, carácter por carácter.